

Resumen Teórico

Probabilidad y Estadística

Contents

1	Teoría de la probabilidad	2
1.1	Espacio muestral y eventos	2
1.2	Axiomas de probabilidad	2
1.3	Espacios equiprobables y técnicas de conteo	2
1.4	Probabilidad condicional	3
1.5	Independencia	3
2	Variables aleatorias	4
2.1	Variables aleatorias discretas	4
2.2	Variables aleatorias continuas	4
2.3	Esperanza	4
2.4	Varianza	4
2.5	Momentos y función generadora	5
3	Distribuciones discretas notables	6
3.1	Bernoulli	6
3.2	Binomial	6
3.3	Geométrica	6
3.4	Binomial negativa	6
3.5	Hipergeométrica	6
3.6	Poisson	6
3.7	Uniforme discreta	6
4	Distribuciones continuas notables	7
4.1	Uniforme	7
4.2	Normal	7
4.3	Exponencial	7
4.4	Gamma	7
4.5	Chi-cuadrado	7
4.6	Weibull	7
4.7	Lognormal	8
4.8	t de Student	8
5	Variables aleatorias conjuntas	9
5.1	Distribuciones conjuntas y marginales	9
5.2	Independencia de variables aleatorias	9
5.3	Covarianza y correlación	9
5.4	Esperanza y varianza condicional	9
6	Muestras aleatorias y teoremas límite	10

1 Teoría de la probabilidad

1.1 Espacio muestral y eventos

Definición 1. El **espacio muestral** Ω de un experimento aleatorio es el conjunto de todos los resultados posibles de dicho experimento. Un **evento** es un subconjunto $A \subseteq \Omega$.

Sobre los eventos se definen las operaciones usuales de conjuntos: unión ($A \cup B$), intersección ($A \cap B$), complemento (A^c) y diferencia ($A - B = A \cap B^c$). Dos eventos A y B son **mutuamente excluyentes** (o disjuntos) si $A \cap B = \emptyset$.

Definición 2. Una colección de eventos $B_1, \dots, B_n$ forma una **partición** de Ω si $B_i \cap B_j = \emptyset$ para $i \neq j$ y $\bigcup_{i=1}^n B_i = \Omega$.

1.2 Axiomas de probabilidad

Definición 3. Una función P definida sobre los eventos de Ω es una **probabilidad** si satisface los axiomas de Kolmogorov:

- (i) $P(A) \geq 0$ para todo evento A .
- (ii) $P(\Omega) = 1$.
- (iii) Para toda sucesión de eventos disjuntos dos a dos $A_1, A_2, \dots$: $P(\bigcup_{i=1}^{\infty} A_i) = \sum_{i=1}^{\infty} P(A_i)$.

De estos axiomas se derivan las siguientes propiedades:

Proposición 1. Para cualesquiera eventos A, B :

$$\begin{aligned} P(\emptyset) &= 0 \\ P(A^c) &= 1 - P(A) \\ \text{si } A \subseteq B: \quad P(A) &\leq P(B), \quad P(B - A) = P(B) - P(A) \\ P(A \cup B) &= P(A) + P(B) - P(A \cap B) \quad (\text{regla de inclusión-exclusión}) \end{aligned}$$

Para tres eventos:

$$P(A \cup B \cup C) = P(A) + P(B) + P(C) - P(A \cap B) - P(A \cap C) - P(B \cap C) + P(A \cap B \cap C).$$

1.3 Espacios equiprobables y técnicas de conteo

Si Ω es finito y todos los resultados son igualmente probables, entonces para cualquier evento A :

$$P(A) = \frac{|A|}{|\Omega|} = \frac{\text{n}^\circ \text{ de resultados favorables}}{\text{n}^\circ \text{ de resultados posibles}}.$$

Las principales herramientas de conteo son:

- **Regla del producto:** si una tarea se realiza en k etapas con $n_1, n_2, \dots, n_k$ opciones en cada una, el número total de formas de completarla es $n_1 \cdot n_2 \cdots n_k$.
- **Permutaciones** de n elementos: $n! = n(n-1) \cdots 1$.
- **Permutaciones** de n elementos tomados de a k (sin repetición, importa el orden): $P_{n,k} = \frac{n!}{(n-k)!}$.
- **Combinaciones** de n elementos tomados de a k (sin repetición, no importa el orden): $\binom{n}{k} = \frac{n!}{k!(n-k)!}$.

1.4 Probabilidad condicional

Definición 4. Dados dos eventos A y B con $P(B) > 0$, la **probabilidad condicional** de A dado B es

$$P(A | B) = \frac{P(A \cap B)}{P(B)}.$$

$P(\cdot | B)$ es en sí misma una probabilidad: satisface los tres axiomas de Kolmogorov sobre el espacio muestral reducido B .

Proposición 2 (Regla del producto).

$$P(A \cap B) = P(A | B) P(B) = P(B | A) P(A).$$

Más generalmente, para eventos $A_1, \dots, A_n$:

$$P(A_1 \cap \dots \cap A_n) = P(A_1) P(A_2 | A_1) P(A_3 | A_1 \cap A_2) \dots P(A_n | A_1 \cap \dots \cap A_{n-1}).$$

Teorema 1 (Probabilidad total). Si $B_1, \dots, B_n$ es una partición de Ω con $P(B_i) > 0$ para todo i , entonces para cualquier evento A :

$$P(A) = \sum_{i=1}^n P(A | B_i) P(B_i).$$

Teorema 2 (Teorema de Bayes). Bajo las mismas condiciones anteriores, si $P(A) > 0$:

$$P(B_i | A) = \frac{P(A | B_i) P(B_i)}{\sum_{j=1}^n P(A | B_j) P(B_j)}.$$

1.5 Independencia

Definición 5. Dos eventos A y B son **independientes** si

$$P(A \cap B) = P(A) P(B).$$

Equivalentemente, si $P(B) > 0$, A y B son independientes si y solo si $P(A | B) = P(A)$.

Proposición 3. Si A y B son independientes, también lo son: A y B^c ; A^c y B ; A^c y B^c .

Definición 6. Los eventos $A_1, \dots, A_n$ son (**mutuamente**) **independientes** si para todo subconjunto de índices $I \subseteq \{1, \dots, n\}$:

$$P\left(\bigcap_{i \in I} A_i\right) = \prod_{i \in I} P(A_i).$$

La independencia dos a dos (pairwise) no implica independencia mutua.

2 Variables aleatorias

Definición 7. Una **variable aleatoria** (v.a.) es una función $X : \Omega \rightarrow \mathbb{R}$ que asigna un número real a cada resultado del espacio muestral.

Definición 8. La **función de distribución acumulada** (cdf) de X es

$$F(x) = P(X \leq x), \quad x \in \mathbb{R}.$$

Toda cdf es no decreciente, continua por derecha, con $\lim_{x \rightarrow -\infty} F(x) = 0$ y $\lim_{x \rightarrow +\infty} F(x) = 1$.

2.1 Variables aleatorias discretas

Definición 9. X es **discreta** si toma valores en un conjunto finito o numerable $\{x_1, x_2, \dots\}$. Su **función de probabilidad de masa** (pmf) es

$$p(x) = P(X = x),$$

que satisface $p(x) \geq 0$ y $\sum_x p(x) = 1$. La cdf se obtiene como $F(x) = \sum_{x_i \leq x} p(x_i)$.

2.2 Variables aleatorias continuas

Definición 10. X es **continua** si existe una función $f(x) \geq 0$, llamada **función de densidad de probabilidad** (pdf), tal que

$$P(a \leq X \leq b) = \int_a^b f(x) dx \quad y \quad \int_{-\infty}^{\infty} f(x) dx = 1.$$

La cdf es $F(x) = \int_{-\infty}^x f(t) dt$, y donde F es derivable, $f(x) = F'(x)$. Para X continua, $P(X = x) = 0$ para todo x .

2.3 Esperanza

Definición 11. La **esperanza** (valor esperado o media) de X es

$$E(X) = \begin{cases} \sum x p(x) & \text{si } X \text{ es discreta} \\ \int_{-\infty}^{\infty} x f(x) dx & \text{si } X \text{ es continua} \end{cases}$$

siempre que la suma o integral converja absolutamente.

Proposición 4 (Esperanza de una función de X). Si $Y = h(X)$:

$$E[h(X)] = \begin{cases} \sum_x h(x) p(x) \\ \int h(x) f(x) dx. \end{cases}$$

Proposición 5 (Linealidad). Para constantes a, b : $E(aX + b) = aE(X) + b$. Más generalmente, $E(X + Y) = E(X) + E(Y)$ para cualesquiera v.a. X, Y (sin requerir independencia).

2.4 Varianza

Definición 12. La **varianza** de X es

$$\text{Var}(X) = E[(X - E(X))^2] = E(X^2) - [E(X)]^2,$$

y la **desviación estándar** es $\sigma_X = \sqrt{\text{Var}(X)}$.

Proposición 6. $\text{Var}(aX + b) = a^2 \text{Var}(X)$. La varianza es siempre no negativa, y $\text{Var}(X) = 0$ si y solo si X es constante (casi seguramente).

2.5 Momentos y función generadora

Definición 13. El *momento de orden k* de X es $E(X^k)$, y el *momento central de orden k* es $E[(X - E(X))^k]$.

Definición 14. La *función generadora de momentos (fgm)* de X , cuando existe en un entorno de 0, es

$$M_X(t) = E(e^{tX}).$$

Se cumple $M_X^{(k)}(0) = E(X^k)$. Si X y Y son independientes, $M_{X+Y}(t) = M_X(t) M_Y(t)$.

3 Distribuciones discretas notables

3.1 Bernoulli

Modela un experimento con dos resultados posibles, éxito (1) y fracaso (0), con probabilidad de éxito p :

$$p(x) = p^x(1-p)^{1-x}, \quad x \in \{0, 1\}, \quad E(X) = p, \quad Var(X) = p(1-p).$$

3.2 Binomial

Suma de n ensayos Bernoulli(p) independientes; X cuenta el número de éxitos:

$$p(x) = \binom{n}{x} p^x (1-p)^{n-x}, \quad x = 0, \dots, n, \quad E(X) = np, \quad Var(X) = np(1-p).$$

Si $X_1 \sim B(n_1, p)$ y $X_2 \sim B(n_2, p)$ son independientes, $X_1 + X_2 \sim B(n_1 + n_2, p)$.

3.3 Geométrica

Número de ensayos Bernoulli(p) independientes hasta obtener el primer éxito (inclusive):

$$p(x) = (1-p)^{x-1}p, \quad x = 1, 2, \dots, \quad E(X) = \frac{1}{p}, \quad Var(X) = \frac{1-p}{p^2}.$$

Satisface la propiedad de **pérdida de memoria**: $P(X > s+t \mid X > s) = P(X > t)$ para $s, t \geq 0$ enteros.

3.4 Binomial negativa

Número de ensayos Bernoulli(p) independientes hasta obtener el r -ésimo éxito:

$$p(x) = \binom{x-1}{r-1} p^r (1-p)^{x-r}, \quad x = r, r+1, \dots, \quad E(X) = \frac{r}{p}, \quad Var(X) = \frac{r(1-p)}{p^2}.$$

Es la suma de r variables Geométricas(p) independientes.

3.5 Hipergeométrica

Número de éxitos al extraer, sin reposición, una muestra de tamaño n de una población de N elementos de los cuales K son éxitos:

$$p(x) = \frac{\binom{K}{x} \binom{N-K}{n-x}}{\binom{N}{n}}, \quad E(X) = n \frac{K}{N}, \quad Var(X) = n \frac{K}{N} \cdot \frac{N-K}{N} \cdot \frac{N-n}{N-1}.$$

3.6 Poisson

Modela el número de ocurrencias de un evento en un intervalo fijo, cuando dichas ocurrencias suceden de manera independiente a una tasa promedio constante λ (proceso de Poisson):

$$p(x) = \frac{e^{-\lambda} \lambda^x}{x!}, \quad x = 0, 1, 2, \dots, \quad E(X) = \lambda, \quad Var(X) = \lambda.$$

Si $X_1 \sim \mathcal{P}(\lambda_1)$ y $X_2 \sim \mathcal{P}(\lambda_2)$ son independientes, $X_1 + X_2 \sim \mathcal{P}(\lambda_1 + \lambda_2)$.

3.7 Uniforme discreta

Todos los valores enteros entre a y b son igualmente probables:

$$p(x) = \frac{1}{b-a+1}, \quad x = a, \dots, b, \quad E(X) = \frac{a+b}{2}, \quad Var(X) = \frac{(b-a+1)^2 - 1}{12}.$$

4 Distribuciones continuas notables

4.1 Uniforme

Densidad constante en un intervalo $[a, b]$:

$$f(x) = \frac{1}{b-a}, \quad a \leq x \leq b, \quad E(X) = \frac{a+b}{2}, \quad Var(X) = \frac{(b-a)^2}{12}.$$

4.2 Normal

Modelo simétrico en forma de campana, caracterizado por su media μ y varianza σ^2 :

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, \quad x \in \mathbb{R}, \quad E(X) = \mu, \quad Var(X) = \sigma^2.$$

Estandarización: si $X \sim N(\mu, \sigma^2)$, entonces $Z = \frac{X - \mu}{\sigma} \sim N(0, 1)$.

Proposición 7. Si $X \sim N(\mu, \sigma^2)$ y $a \neq 0$, entonces $Y = aX + b \sim N(a\mu + b, a^2\sigma^2)$. Toda combinación lineal de variables normales independientes es normal.

4.3 Exponencial

Modela el tiempo de espera hasta el primer evento de un proceso de Poisson de tasa λ :

$$f(x) = \lambda e^{-\lambda x}, \quad x \geq 0, \quad F(x) = 1 - e^{-\lambda x}, \quad E(X) = \frac{1}{\lambda}, \quad Var(X) = \frac{1}{\lambda^2}.$$

Tiene **pérdida de memoria**: $P(X > s + t \mid X > s) = P(X > t)$, siendo la única distribución continua con esta propiedad.

4.4 Gamma

Generaliza la exponencial: modela el tiempo hasta que ocurren α eventos de un proceso de Poisson. Con parámetro de forma $\alpha > 0$ y de escala $\beta > 0$:

$$f(x) = \frac{1}{\beta^\alpha \Gamma(\alpha)} x^{\alpha-1} e^{-x/\beta}, \quad x \geq 0, \quad E(X) = \alpha\beta, \quad Var(X) = \alpha\beta^2,$$

donde $\Gamma(\alpha) = \int_0^\infty t^{\alpha-1} e^{-t} dt$ es la función Gamma ($\Gamma(n) = (n-1)!$ para $n \in \mathbb{N}$). Si $\alpha = 1$, se reduce a la Exponencial con $\lambda = 1/\beta$. La suma de α (entero) exponenciales ($1/\beta$) independientes es Gamma(α, β).

4.5 Chi-cuadrado

Caso particular de la Gamma con $\alpha = k/2$, $\beta = 2$, donde k es el número de grados de libertad:

$$f(x) = \frac{1}{2^{k/2} \Gamma(k/2)} x^{k/2-1} e^{-x/2}, \quad x \geq 0, \quad E(X) = k, \quad Var(X) = 2k.$$

Si $Z_1, \dots, Z_k$ son normales estándar independientes, $\sum_{i=1}^k Z_i^2 \sim \chi_k^2$.

4.6 Weibull

Generaliza la exponencial, permitiendo tasas de falla crecientes o decrecientes, con forma $\alpha > 0$ y escala $\beta > 0$:

$$f(x) = \frac{\alpha}{\beta^\alpha} x^{\alpha-1} e^{-(x/\beta)^\alpha}, \quad x \geq 0, \quad F(x) = 1 - e^{-(x/\beta)^\alpha},$$
$$E(X) = \beta \Gamma\left(1 + \frac{1}{\alpha}\right), \quad Var(X) = \beta^2 \left[\Gamma\left(1 + \frac{2}{\alpha}\right) - \Gamma\left(1 + \frac{1}{\alpha}\right)^2 \right].$$

Si $\alpha = 1$, se reduce a la Exponencial de parámetro $1/\beta$.

4.7 Lognormal

X es lognormal si $\ln X \sim N(\mu, \sigma^2)$:

$$f(x) = \frac{1}{x\sigma\sqrt{2\pi}} e^{-\frac{(\ln x - \mu)^2}{2\sigma^2}}, \quad x > 0, \quad E(X) = e^{\mu + \sigma^2/2}, \quad Var(X) = (e^{\sigma^2} - 1) e^{2\mu + \sigma^2}.$$

4.8 t de Student

Distribución simétrica de colas más pesadas que la normal, con k grados de libertad:

$$f(x) = \frac{\Gamma(\frac{k+1}{2})}{\sqrt{k\pi} \Gamma(\frac{k}{2})} \left(1 + \frac{x^2}{k}\right)^{-\frac{k+1}{2}}, \quad x \in \mathbb{R},$$

$$E(X) = 0 \quad (k > 1), \quad Var(X) = \frac{k}{k-2} \quad (k > 2).$$

Surge de $T = \frac{Z}{\sqrt{V/k}}$ con $Z \sim N(0, 1)$ y $V \sim \chi_k^2$ independientes; converge a $N(0, 1)$ cuando $k \rightarrow \infty$.

5 Variables aleatorias conjuntas

5.1 Distribuciones conjuntas y marginales

Definición 15. Para dos v.a. discretas X, Y , la **función de probabilidad conjunta** es $p(x, y) = P(X = x, Y = y)$, con $\sum_x \sum_y p(x, y) = 1$. Para v.a. continuas, la **densidad conjunta** $f(x, y) \geq 0$ satisface $\iint f(x, y) dx dy = 1$, y $P((X, Y) \in A) = \iint_A f(x, y) dx dy$.

Definición 16. Las **distribuciones marginales** se obtienen sumando o integrando sobre la otra variable:

$$p_X(x) = \sum_y p(x, y), \quad f_X(x) = \int_{-\infty}^{\infty} f(x, y) dy,$$

y análogamente para Y .

Definición 17. La **distribución condicional** de Y dado $X = x$ es

$$p_{Y|X}(y | x) = \frac{p(x, y)}{p_X(x)} \quad \text{ó} \quad f_{Y|X}(y | x) = \frac{f(x, y)}{f_X(x)},$$

definida cuando $p_X(x) > 0$ (o $f_X(x) > 0$).

5.2 Independencia de variables aleatorias

Definición 18. X y Y son **independientes** si para todo x, y :

$$p(x, y) = p_X(x) p_Y(y) \quad (\text{discretas}), \quad f(x, y) = f_X(x) f_Y(y) \quad (\text{continuas}).$$

Equivalentemente, si $F(x, y) = F_X(x) F_Y(y)$ para todo x, y .

Proposición 8. Si X, Y son independientes, entonces para funciones g, h cualesquiera, $E[g(X)h(Y)] = E[g(X)]E[h(Y)]$; en particular $E(XY) = E(X)E(Y)$.

5.3 Covarianza y correlación

Definición 19.

$$\text{Cov}(X, Y) = E[(X - E(X))(Y - E(Y))] = E(XY) - E(X)E(Y).$$

El **coeficiente de correlación** es

$$\rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}, \quad -1 \leq \rho \leq 1.$$

Proposición 9. • $\text{Cov}(X, X) = \text{Var}(X)$.

- $\text{Cov}(aX + b, cY + d) = ac \text{Cov}(X, Y)$.
- Si X, Y son independientes, $\text{Cov}(X, Y) = 0$ (la recíproca no es cierta en general: covarianza cero no implica independencia).
- $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y)$; si son independientes, $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$.
- En general, $\text{Var}(\sum_i a_i X_i) = \sum_i a_i^2 \text{Var}(X_i) + 2 \sum_{i < j} a_i a_j \text{Cov}(X_i, X_j)$.

5.4 Esperanza y varianza condicional

Proposición 10 (Ley de la esperanza total).

$$E(X) = E[E(X | Y)].$$

Proposición 11 (Ley de la varianza total).

$$\text{Var}(X) = E[\text{Var}(X | Y)] + \text{Var}[E(X | Y)].$$

6 Muestras aleatorias y teoremas límite

Definición 20. Una **muestra aleatoria** de tamaño n es una colección $X_1, \dots, X_n$ de v.a. independientes e idénticamente distribuidas (iid), cada una con la misma distribución que una v.a. poblacional X , con $E(X) = \mu$ y $Var(X) = \sigma^2$.

Definición 21. La **media muestral** es $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$, y la **suma muestral** es $T = \sum_{i=1}^n X_i$.

Proposición 12. Para una muestra aleatoria de tamaño n :

$$E(\bar{X}) = \mu, \quad Var(\bar{X}) = \frac{\sigma^2}{n}, \quad E(T) = n\mu, \quad Var(T) = n\sigma^2.$$

Teorema 3 (Ley (débil) de los Grandes Números). Si $X_1, \dots, X_n$ son iid con media μ finita, entonces $\bar{X}$ converge en probabilidad a μ cuando $n \rightarrow \infty$: para todo $\varepsilon > 0$,

$$\lim_{n \rightarrow \infty} P(|\bar{X} - \mu| > \varepsilon) = 0.$$

Teorema 4 (Teorema Central del Límite). Si $X_1, \dots, X_n$ son iid con media μ y varianza $\sigma^2 < \infty$, entonces, cuando $n \rightarrow \infty$, la distribución de

$$Z_n = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} = \frac{T - n\mu}{\sigma\sqrt{n}}$$

converge a la distribución $N(0, 1)$. En la práctica, para n suficientemente grande:

$$\bar{X} \stackrel{\text{aprox.}}{\sim} N\left(\mu, \frac{\sigma^2}{n}\right), \quad T \stackrel{\text{aprox.}}{\sim} N(n\mu, n\sigma^2).$$

Corolario 1 (Aproximación normal a la Binomial). Si $X \sim B(n, p)$ con n grande, X puede verse como una suma de n Bernoulli(p) iid, por lo que

$$X \stackrel{\text{aprox.}}{\sim} N(np, np(1-p)).$$

Suele usarse cuando $np \geq 5$ y $n(1-p) \geq 5$, con corrección por continuidad:

$$P(X \leq x) \approx P\left(Z \leq \frac{x + 0.5 - np}{\sqrt{np(1-p)}}\right).$$

Proposición 13 (Combinación de dos medias muestrales independientes). Si $\bar{X}$ y $\bar{Y}$ provienen de muestras independientes de tamaños n y m , de poblaciones con medias μ_X, μ_Y y varianzas σ_X^2, σ_Y^2 , entonces, para n, m grandes,

$$\bar{X} - \bar{Y} \stackrel{\text{aprox.}}{\sim} N\left(\mu_X - \mu_Y, \frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{m}\right).$$