

3. Probabilidad condicional

Definición

$$\mathcal{P}(A|B) = \frac{\mathcal{P}(A \cap B)}{\mathcal{P}(B)}, \quad \mathcal{P}(B) > 0$$

Regla de la multiplicación

$$\mathcal{P}(A \cap B) = \mathcal{P}(A|B) \cdot \mathcal{P}(B)$$

Sucesos independientes: B no aporta información sobre A :

$$\mathcal{P}(A|B) = \mathcal{P}(A) \iff \mathcal{P}(A \cap B) = \mathcal{P}(A) \cdot \mathcal{P}(B)$$

Regla de la Probabilidad Total Si $B_1, \dots, B_r$ son sucesos exhaustivos ($\Omega = \cup_i B_i$) y excluyentes ($B_i \cap B_j = \emptyset, i \neq j$), con $\mathcal{P}(B_i) > 0$:

$$\mathcal{P}(A) = \sum_{i=1}^r \mathcal{P}(A|B_i) \mathcal{P}(B_i)$$

Regla de Bayes

$$\mathcal{P}(B_j|A) = \frac{\mathcal{P}(B_j \cap A)}{\mathcal{P}(A)} = \frac{\mathcal{P}(A|B_j) \mathcal{P}(B_j)}{\sum_{i=1}^r \mathcal{P}(A|B_i) \mathcal{P}(B_i)}$$

Útil para obtener $\mathcal{P}(B_i|A)$ a partir de las $\mathcal{P}(A|B_j)$ (probabilidades “en el sentido contrario”).

4. Variable aleatoria (concepto y v.a. discretas)

Definición. Una variable aleatoria X es una función $X : \Omega \rightarrow \mathbb{R}$ que a cada elemento del espacio muestral le asigna un número real. “Hereda” de Ω la probabilidad $\mathcal{P}$.

Rango de la v.a.: $\Omega_X = \{x \in \mathbb{R} : \exists s \in \Omega, X(s) = x\}$

- Si Ω_X es finito o numerable $\rightarrow$ v.a. **discreta**.
- Si Ω_X es un intervalo (finito o infinito) $\rightarrow$ v.a. **continua**.

Probabilidad inducida: $\mathcal{P}(A) = \mathcal{P}(X \in A) = \mathcal{P}(s \in \Omega : X(s) \in A)$

Función de masa (v.a. discreta)

$$p(x_i) = \mathcal{P}(X = x_i) = \mathcal{P}(s \in \Omega : X(s) = x_i)$$

Propiedades: (1) $0 \leq p(x) \leq 1$; (2) $\sum_i p(x_i) = 1$; (3) $\mathcal{P}(X \in A) = \sum_{x_i \in A} p(x_i)$.

Función de distribución (acumulada) F

$$F(x) = \mathcal{P}(-\infty, x] = \mathcal{P}(s \in \Omega : X(s) \leq x), \quad \forall x \in \mathbb{R}$$

Propiedades:

1. $\lim_{x \rightarrow -\infty} F(x) = 0$
2. $\lim_{x \rightarrow \infty} F(x) = 1$
3. $x_1 < x_2 \Rightarrow F(x_1) \leq F(x_2)$ (monótona no decreciente)
4. $F(x^+) = \lim_{h \rightarrow 0^+} F(x+h) = F(x)$ (continua por la derecha)

- Consecuencia: $P(a, b] = F(b) - F(a)$
- Para v.a. discreta: $F(x) = \sum_{x_i \leq x} p(x_i)$ — función escalón (continua a trozos).

Transformación de variables aleatorias (discretas)

Dada X y $g: \mathbb{R} \rightarrow \mathbb{R}$, $Y = g(X)$:

- Función de masa: $p_Y(y) = P(Y = y) = P(g(X) = y) = \sum_{g(x)=y} p_X(x)$
- Función de distribución: $F_Y(y) = P_X(A_y)$ con $A_y = \{x : g(x) \leq y\}$

5. Medidas características de una variable aleatoria

Esperanza (media)

$$\mu_X = E[X] = \sum_i x_i p_X(x_i)$$

- Interpretación: valor promedio ponderado por probabilidad; “centro de gravedad” de la distribución; límite de la ganancia media en repeticiones (frecuentista).
- Para I indicador de A : $E[I] = P(A)$.

Propiedades (con X, Y v.a. de esperanza finita, $a, b, c \in \mathbb{R}$):

1. $E[c] = c$
2. $E[aX] = aE[X]$
3. Si $X \geq 0 \Rightarrow E[X] \geq 0$
4. Si $X \leq Y \Rightarrow E[X] \leq E[Y]$
5. Si $a \leq X \leq b$ entonces $a \leq E[X] \leq b$
6. $E[a + bX] = a + bE[X]$
7. Esperanza de una función: $\mu_Y = E[g(X)] = \sum_i g(x_i) p_X(x_i)$
8. El mejor predictor (en error cuadrático medio) de X es $\mu = E[X]$: minimiza $E[(X - c)^2]$.

Moda y Mediana

- **Mediana** Me : valor tal que $P(X < Me) \leq \frac{1}{2}$ y $P(X \leq Me) \geq \frac{1}{2}$. Para v.a. discreta: primer valor que acumula probabilidad $\geq 1/2$.
- **Moda**: valor(es) de mayor probabilidad.

Medidas de variabilidad — Varianza

$$\sigma_X^2 = V(X) = E[(X - \mu_X)^2] = \sum_i (x_i - \mu_X)^2 p_X(x_i)$$

Fórmula alternativa (más práctica): $\sigma_X^2 = E[X^2] - \mu_X^2$

- σ (raíz cuadrada de $V(X)$) = **desviación típica/estándar**.
- $\mu_2 = E[(X - \mu_X)^2]$ = momento central de orden 2.

Propiedades: $V(X) = E[X^2] - (E[X])^2 \geq 0$; $V(aX) = a^2 V(X)$; $V(b) = 0$; $V(aX + b) = a^2 V(X)$.

Desigualdad de Chebyshev: $P(|X - \mu_X| > k\sigma_X) \leq \frac{1}{k^2}$

Coefficiente de variación: $CV_X = \frac{\sigma_X}{\mu_X}$ — mide dispersión relativa (independiente de escala).

Momentos

- **Momento ordinario de orden k:** $\alpha_k = E[X^k]$ (el de orden 1 es la media).
- **Momento central de orden k:** $\mu_k = E[(X - \mu_X)^k]$ (el de orden 1 es siempre 0).
- Dos v.a. con los mismos momentos tienen la misma distribución de probabilidad (los momentos caracterizan la distribución).

6. Distribuciones discretas conocidas

Degenerada

$X \equiv \delta_c: P(X = c) = 1, E[X] = c, V(X) = 0.$

Uniforme discreta

$X \sim \text{Unif}\{x_1, \dots, x_n\}: p(x_i) = 1/n.$

$$E[X] = \frac{1}{n} \sum_i x_i \quad V(X) = \frac{1}{n} \sum_i x_i^2 - \left(\frac{1}{n} \sum_i x_i \right)^2$$

Bernoulli

$X \sim \text{Bern}(p)$: experimento con dos resultados (éxito E , fracaso F), $P(E) = p.$

$$P(X = x) = p^x(1-p)^{1-x}, x = 0, 1 \quad E[X] = p \quad V(X) = p(1-p) = pq$$

Binomial

$X \sim B(n, p)$: suma de n Bernoulli(p) independientes = número de éxitos en n pruebas.

$$P(X = x) = \binom{n}{x} p^x (1-p)^{n-x}, x = 0, \dots, n \quad E[X] = np \quad V(X) = npq$$

Poisson

$X \sim \mathbb{P}(\lambda)$: número de sucesos en un tiempo/espacio dado con tasa media conocida λ (sucesos “raros”, independientes).

$$P(X = x) = \frac{e^{-\lambda} \lambda^x}{x!}, x = 0, 1, 2, \dots \quad E[X] = V(X) = \lambda$$

- Suma de Poisson independientes: $\sum_i X_i \sim \mathbb{P}(\sum_i \lambda_i).$
- Aproxima a la Binomial cuando $n \rightarrow \infty, p \rightarrow 0, np = \lambda$ constante (útil cuando n grande y p pequeño).

Hipergeométrica

$X \sim \mathcal{H}(r_1, r, n)$: se extrae sin reposición una muestra de tamaño n de una población de r objetos, de los cuales r_1 son de un tipo. X = número de objetos del tipo 1 en la muestra.

$$p_X(x) = \frac{\binom{r_1}{x} \binom{r-r_1}{n-x}}{\binom{r}{n}} \quad E[X] = \frac{nr_1}{r} \quad V(X) = \frac{r_1 n (r-r_1)(r-n)}{r^2 (r-1)}$$

Geométrica

$X \sim \mathcal{G}(p)$: n° de experimentos Bernoulli(p) hasta obtener el **primer** éxito (inclusive). $X \in \{1, 2, 3, \dots\}$.

$$P(X = k) = (1-p)^{k-1}p, k = 1, 2, \dots \quad E[X] = \frac{1}{p} \quad V(X) = \frac{1-p}{p^2}$$

Propiedades:

- $F_X(t) = 1 - (1-p)^{\lfloor t \rfloor}, t \geq 1$
- $P(X \geq k) = (1-p)^{k-1}$
- **Propiedad de “amnesia” (pérdida de memoria):** $P(X \geq s+t \mid X > t) = P(X \geq s)$
- Variante: Y = n° de **fracasos** antes del primer éxito, $Y = X - 1, p_Y(k) = p(1-p)^k, k = 0, 1, 2, \dots$

Binomial Negativa (Pascal)

$X \sim \mathcal{BN}(r, p)$: n° de experimentos Bernoulli(p) independientes necesarios para obtener r éxitos.

$$p_X(k) = \binom{k-1}{r-1} (1-p)^{k-r} p^r, k = r, r+1, \dots \quad E[X] = \frac{r}{p} \quad V(X) = \frac{r(1-p)}{p^2}$$

- Si Y = número de fracasos hasta obtener r éxitos: $Y = X - r$, con $p_Y(k) = \binom{k+r-1}{r-1} (1-p)^k p^r$.
- Caso $r = 1$: coincide con la Geométrica.

7. Variable aleatoria continua

Definición. X es continua si su función de distribución acumulada F es una función continua (no tiene saltos).

Densidad de probabilidad: f es densidad de X con distribución F si $f \geq 0$ y

$$F(t) = \int_{-\infty}^t f(x) dx$$

- La densidad **no es única** en los puntos donde F no es derivable; donde F es derivable, $f(t) = F'(t)$.
- Condición de densidad válida: $f \geq 0$ y $\int_{-\infty}^{\infty} f(x) dx = 1$.

Propiedades

$$P(a \leq X \leq b) = \int_a^b f(x) dx = F(b) - F(a)$$

Para v.a. continua: $P(a \leq X \leq b) = P(a < X < b) = P(a \leq X < b) = P(a < X \leq b)$ (los puntos individuales tienen probabilidad 0).

Transformación de variables continuas: si $Y = a + bX$ ($b \neq 0$):

$$f_Y(y) = \frac{1}{|b|} f_X\left(\frac{y-a}{b}\right)$$

Distribución condicional: para $A, B \subset \mathbb{R}_X$,

$$P(X \in A \mid X \in B) = \frac{P(X \in A \cap B)}{P(X \in B)} = \frac{\int_{A \cap B} f(y) dy}{\int_B f(y) dy}$$

Esperanza y varianza (v.a. continua)

$$E[X] = \int_{-\infty}^{\infty} xf(x)dx \quad (\text{si } \int_{-\infty}^{\infty} |x|f(x)dx < \infty) \quad V(X) = E[X^2] - (E[X])^2, \quad \sigma = \sqrt{V(X)}$$

Propiedades: $0 \leq V(X)$; $E(aX + b) = aE(X) + b$; $V(aX + b) = a^2V(X)$; para h función, $E[h(X)] = \int h(x)f(x)dx$ (si $\int |h(x)|f(x)dx < \infty$).

Cuantiles y percentiles

- **Cuantil de orden** $p \in (0, 1)$: $\eta(p)$ tal que $p = F(\eta(p))$, i.e. $p = \int_{-\infty}^{\eta(p)} f(t)dt$.
- Cuartiles: dividen en 4 partes (25%, 50%, 75%); quintiles: 5 partes; deciles: 10 partes; percentiles: 100 partes.
- Si $Y = aX + b$: $\eta_Y(p) = a\eta_X(p) + b$ si $a > 0$; $\eta_Y(p) = a\eta_X(1 - p) + b$ si $a < 0$.

8. Distribuciones continuas conocidas

Uniforme continua

$X \sim U[a, b]$, $a < b$:

$$f(x) = \frac{1}{b-a}, \quad a < x < b \quad F(x) = \begin{cases} 0 & x < a \\ \frac{x-a}{b-a} & a \leq x \leq b \\ 1 & x > b \end{cases}$$

$$E(X) = \frac{a+b}{2} \quad V(X) = \frac{(b-a)^2}{12}$$

Propiedad clave: si $X \sim U[0, 1]$ y F es continua estrictamente creciente, $Y = F^{-1}(X)$ tiene distribución acumulada F (método de la transformada inversa: simular cualquier distribución a partir de una uniforme).

Distribución Gamma

Dos parametrizaciones equivalentes:

- Forma α y tasa λ : $X \sim \Gamma(\alpha, \lambda)$, $f(x) = \frac{\lambda^\alpha x^{\alpha-1} e^{-\lambda x}}{\Gamma(\alpha)}$, $x > 0$
- Forma α y escala $\beta = 1/\lambda$: $X \sim \Gamma(\alpha, \beta)$, $f(x) = \frac{1}{\beta^\alpha \Gamma(\alpha)} x^{\alpha-1} e^{-x/\beta}$, $x > 0$

Función Gamma de Euler: $\Gamma(\alpha) = \int_0^\infty x^{\alpha-1} e^{-x} dx$ ($\alpha > 0$). Propiedades: $\Gamma(\alpha) = (\alpha - 1)\Gamma(\alpha - 1)$; $\Gamma(n) = (n - 1)!$ para $n \in \mathbb{N}$; $\Gamma(1/2) = \sqrt{\pi}$.

$$E[X] = \alpha\beta = \alpha/\lambda \quad V(X) = \alpha\beta^2 = \alpha/\lambda^2$$

Propiedad: si $X \sim \Gamma(\alpha, \lambda)$ y $a > 0$ entonces $aX \sim \Gamma(\alpha, \lambda/a)$. Casos particulares de la familia Gamma: **Exponencial, Erlang, Chi-cuadrado**.

Distribución Exponencial

$X \sim \mathcal{E}(\lambda) = \Gamma(1, \lambda)$, $\lambda > 0$:

$$f(x) = \lambda e^{-\lambda x}, \quad x \geq 0 \quad F(x) = 1 - e^{-\lambda x}, \quad x \geq 0$$

$$E(X) = 1/\lambda \quad V(X) = 1/\lambda^2$$

Propiedades:

- **Falta de memoria:** $P(X \geq t + t_0 \mid X \geq t_0) = P(X \geq t)$ para todo $t \geq 0$.
- Modela tiempos de espera/vida sin desgaste (tiempo entre eventos de un proceso de Poisson).
- Si $X \sim \mathcal{E}(\lambda)$, $c > 0$ () $cX \sim \mathcal{E}(\lambda/c)$.
- Mínimo de exponenciales independientes: si $X_1, \dots, X_n \sim \mathcal{E}(\lambda_i)$ independientes, $\min(X_1, \dots, X_n) \sim \mathcal{E}(\sum_i \lambda_i)$.

Distribución Chi-cuadrado

$X \sim \chi^2(k)$ (k grados de libertad) $= \Gamma(k/2, 1/2)$ [o $\Gamma(k/2, \beta = 2)$]:

$$f(x) = \frac{1}{2^{k/2} \Gamma(k/2)} x^{k/2-1} e^{-x/2}, \quad x \geq 0$$

- Si $Z_1, \dots, Z_n$ son $N(0, 1)$ independientes, entonces $X = Z_1^2 + \dots + Z_n^2 \sim \chi^2(n)$.
- $\chi^2(2)$ coincide con $\mathcal{E}(1/2)$.
- $E(X) = k$, $Var(X) = 2k$.
- **Cuantiles:** $\chi_{k,\alpha}^2$ tal que $P(X \geq \chi_{k,\alpha}^2) = \alpha$ (se buscan en tabla por fila = g.d.l., columna = nivel de significancia α).

Distribución Weibull

$X \sim W(\alpha, \beta)$, $\alpha, \beta > 0$:

$$f(x) = \frac{\alpha}{\beta^\alpha} x^{\alpha-1} e^{-(x/\beta)^\alpha}, \quad x \geq 0 \quad F(x) = 1 - e^{-(x/\beta)^\alpha}, \quad x > 0$$

$$E(X) = \beta \Gamma(1 + 1/\alpha) \quad V(X) = \beta^2 [\Gamma(1 + 2/\alpha) - \Gamma(1 + 1/\alpha)^2]$$

- Si $\alpha = 1$: $W(1, \beta) = \mathcal{E}(1/\beta)$.
- Weibull y Gamma son generalizaciones de la Exponencial pero son modelos **distintos**: Gamma describe el tiempo de espera hasta k eventos de Poisson; Weibull describe el tiempo de espera cuando la probabilidad del evento cambia con el tiempo (tasa de fallo/desgaste). Weibull decae más rápido si $k > 1$ y más lento si $k < 1$.

Distribución Normal (Gaussiana)

$X \sim N(\mu, \sigma^2)$:

$$f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, \quad -\infty < x < \infty$$

- $E(X) = \mu$; $V(X) = \sigma^2$; simétrica respecto a μ ; forma de campana; $\lim_{x \rightarrow \pm\infty} f(x) = 0$.
- No tiene primitiva elemental () se usa la **Normal estándar** $Z \sim N(0, 1)$: $\varphi(z) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2}$, $\Phi(z) = P(Z \leq z)$ (tabulada).
- **Estandarización:** si $X \sim N(\mu, \sigma^2)$, $Z = \frac{X - \mu}{\sigma} \sim N(0, 1)$; inversamente $Y = \mu + \sigma Z \sim N(\mu, \sigma^2)$.
- Propiedades de manejo de tabla (cola a izquierda):
 - $P(Z \geq z) = 1 - \Phi(z)$
 - $P(Z \leq -z) = P(Z \geq z) = 1 - \Phi(z)$, $z > 0$
 - $P(-z \leq Z \leq z) = 2\Phi(z) - 1$, $z > 0$
 - $P(z_1 \leq Z \leq z_2) = \Phi(z_2) - \Phi(z_1)$
 - Para calcular $P(a < X < b)$ con $X \sim N(\mu, \sigma^2)$: estandarizar y usar $\Phi\left(\frac{b-\mu}{\sigma}\right) - \Phi\left(\frac{a-\mu}{\sigma}\right)$.
- **Teorema Central del Límite:** la suma/promedio de un gran número de v.a. independientes tiende a distribución normal, aun si las variables individuales no lo son (fundamenta el uso de la normal como aproximación).

Distribución Log-normal

$X \sim \text{lognormal}(\mu, \sigma)$ si $Y = \ln X \sim N(\mu, \sigma^2)$ ($X > 0$):

$$f_X(x) = \frac{1}{x\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{\ln x - \mu}{\sigma}\right)^2}, \quad x > 0$$

$$F(x) = \Phi\left(\frac{\ln x - \mu}{\sigma}\right)$$

$$E(X^n) = \exp\left(\frac{n^2\sigma^2}{2} + n\mu\right) \Rightarrow E(X) = e^{\mu+\sigma^2/2}, \quad \text{Var}(X) = e^{2\mu+2\sigma^2}(e^{\sigma^2} - 1)$$

(demostración vía cambio de variable $t = \frac{\ln x - \mu}{\sigma}$, completando cuadrados).